

# Aplicativo Móvil para la segmentación y clasificación del Alzheimer

Roddy Pérez<sup>1</sup>, Paulo Guzmán, Ian Quispe<sup>3</sup>, Ivan Petrlik<sup>4</sup>

Facultad de Ingeniería de Sistemas e Informática, Universidad Nacional Mayor de San Marcos, Lima, Perú<sup>1,2</sup>

Facultad de Ingeniería Eléctrica, Electrónica, Informática y Mecánica, Universidad Nacional de San Antonio Abad del Cusco, Cusco, Perú<sup>3</sup> Facultad de Ingeniería Industrial y Sistemas, Universidad Nacional Federico Villarreal, Lima, Perú<sup>4</sup>

**Abstract**—This paper presents the development of a mobile application based on artificial intelligence for the segmentation and classification of Alzheimer's disease. The process was carried out following the Design Thinking methodology, including the stages of empathize, define, ideate, prototype, and test. Data were collected from neurologist doctors, medical students, patients, and family members to understand their needs, challenges, and expectations. The prototype integrates brain image (MRI) uploading, automatic AI analysis, interactive heatmaps, disease stage classification, and reports for both doctors and patients. The testing phase with real users validated the functionality, usability, and clarity of the results, incorporating improvements based on direct feedback. This approach enables a clinical, educational, and human-centered tool to facilitate early Alzheimer's diagnosis, optimizing communication between doctors, patients, and family members.

**Keywords**—Alzheimer's disease; Artificial Intelligence; Mobile application; Design Thinking; Diagnosis; Segmentation; Usability; Prototype.

## I. INTRODUCTION

El Alzheimer constituye un problema de salud pública debido a su alta prevalencia, impacto en la calidad de vida y la necesidad de un diagnóstico temprano para intervenir oportunamente (Aghili et al., 2018; Bootun et al., 2025; Liu et al., 2020). La detección y clasificación de los distintos grados de afectación cerebral aún dependen en gran medida de la experiencia del especialista y de la disponibilidad de recursos avanzados, lo que genera variabilidad en los diagnósticos y un acceso desigual a atención oportuna (Dakshinamoorthy et al., 2025; Morra et al., 2019; Nan et al., 2022).

Si bien las técnicas de inteligencia artificial aplicadas a imágenes de resonancia magnética (MRI) han demostrado un gran potencial para la segmentación y clasificación de patrones asociados al Alzheimer, la mayoría de las soluciones requieren infraestructura compleja o permanecen en fases experimentales (Vinukonda & Jagadesh, 2024; Jumaili & Sonuç, 2025; Nour et al., 2024). Esta brecha limita la disponibilidad de herramientas accesibles y portátiles que permitan apoyar la toma de decisiones clínicas en entornos con recursos limitados, donde la detección temprana es crítica para la intervención y el seguimiento de los pacientes (Islam & Alyasiri, 2019; Sangeetha & Nair, 2023).

Diversas investigaciones han demostrado que la inteligencia artificial, mediante modelos de aprendizaje profundo y técnicas híbridas, puede asistir eficazmente en la segmentación y clasificación de imágenes cerebrales, mejorando la precisión diagnóstica y reduciendo el sesgo subjetivo del especialista (Shaffi et al., 2024; Wang et al., 2018; You et al., 2022). Sin embargo, estas soluciones suelen requerir equipos especializados y conocimientos técnicos avanzados, lo que restringe su aplicabilidad en clínicas y hospitales con recursos limitados (Ibáñez et al., 2012; Wang et al., 2024).

Ante esta brecha surge la necesidad de desarrollar aplicaciones móviles accesibles, seguras y eficientes que integren algoritmos de segmentación y clasificación, permitiendo a los médicos analizar imágenes de MRI, generar mapas de calor de regiones afectadas y proporcionar informes comprensibles para pacientes y familiares. Un aplicativo móvil de estas características no solo facilita el diagnóstico temprano del Alzheimer, sino que también democratiza el acceso a herramientas de apoyo diagnóstico, mejora la comunicación clínica y contribuye al seguimiento de la evolución del paciente (Liu et al., 2020; Morra et al., 2019; Vinukonda & Jagadesh, 2024).

**Objetivo General:** Desarrollar y validar un sistema integral de inteligencia artificial (IA) para la detección temprana, clasificación del grado de afectación y seguimiento evolutivo del Alzheimer en pacientes, mediante el análisis automatizado de imágenes de resonancia magnética (MRI), complementado con reportes interpretativos para médicos y pacientes o familiares.

### Objetivos Específicos:

1) Implementar y comparar algoritmos de aprendizaje profundo, incluyendo modelos de segmentación y clasificación cerebral, para la identificación automática de regiones afectadas por Alzheimer y determinación del grado de afectación (leve, moderado o avanzado) (Vinukonda & Jagadesh, 2024; Liu et al., 2020).

2) Validar el rendimiento diagnóstico del sistema de IA frente a la evaluación de especialistas en neurología, midiendo métricas de precisión, sensibilidad, especificidad y concordancia clínica en la detección de deterioro cognitivo (Morra et al., 2019; Jumaili & Sonuç, 2025).

3) Integrar la generación de mapas de calor y reportes duales (médico y paciente/familiar) para facilitar la interpretación clínica y la comunicación de resultados, asegurando comprensión y seguimiento del paciente (Bootun et al., 2025; Sangeetha & Nair, 2023).

4) Evaluar la utilidad del historial de análisis previos del paciente para monitorear la evolución de la enfermedad, detectar progresión o mejoría, y apoyar la planificación de futuras intervenciones médicas (Aghili et al., 2018; Nan et al., 2022).

## II. ANTECEDENTES

El trabajo de Aghili, M. et al. (2018) propone el uso de redes neuronales recurrentes (RNN) para modelar datos longitudinales en el diagnóstico del Alzheimer, destacando la capacidad de estos modelos para identificar patrones tempranos de progresión de la enfermedad y apoyar decisiones clínicas.

Bootun, D. et al. (2025) desarrollaron ADAMAEX, un sistema de clasificación de Alzheimer mediante autoencoders potenciados con atención y técnicas de XAI, logrando explicar las decisiones del modelo y facilitando la interpretación para médicos y familiares.

Dakshinamoorthy, C. et al. (2025) presentan un modelo híbrido que combina optimización bioinspirada y aprendizaje profundo para la identificación del Alzheimer, mejorando la precisión diagnóstica en comparación con métodos tradicionales.

Ibáñez, C. et al. (2012) trabajaron en un modelo predictivo de progresión del Alzheimer usando metabolómica por espectrometría de masas, enfatizando la importancia de integrar datos biológicos y clínicos para predicción temprana.

Islam, M. T., & Alyasiri, S. A. (2019) demostraron que el aprendizaje por transferencia con selección inteligente de datos de entrenamiento mejora la predicción de Alzheimer, optimizando la generalización del modelo con conjuntos de datos limitados.

Jumaili, M. L. F., & Sonuç, E. (2025) desarrollaron un marco de CNN basado en atención para el estadiaje del Alzheimer con visualización XAI, lo que permite a los especialistas comprender mejor las regiones cerebrales afectadas.

Liu, S. et al. (2020) propusieron un modelo de deep learning automatizado basado en MRI para detectar el proceso de Alzheimer, subrayando la capacidad de las redes convolucionales para segmentar y clasificar regiones cerebrales con alta precisión.

Morra, J. H. et al. (2019) utilizaron imágenes de resonancia magnética del hipocampo en un modelo de deep learning para predecir tempranamente la demencia asociada al Alzheimer, demostrando que la detección precoz es posible antes de la aparición de síntomas clínicos evidentes.

Nan, F. et al. (2022) desarrollaron un marco de evaluación multi-clasificación para la reproducibilidad en el aprendizaje multimodal en Alzheimer, asegurando la consistencia de los resultados entre distintas modalidades de imágenes cerebrales.

Nour, M. et al. (2024) diseñaron un modelo híbrido basado en señales EEG y deep ensemble learning para el diagnóstico y clasificación del Alzheimer, mostrando que la combinación de distintas fuentes de datos incrementa la exactitud del diagnóstico.

Sangeetha, S., & Nair, S. A. (2023) realizaron una revisión sistemática sobre técnicas de machine learning y deep learning en el diagnóstico efectivo del Alzheimer, destacando la tendencia hacia modelos interpretables y multimodales.

Shaffi, N. et al. (2024) evaluaron el rendimiento de métodos de aprendizaje profundo, superficial y ensembles para la clasificación automatizada del Alzheimer, evidenciando que los modelos combinados ofrecen mejor robustez y precisión.

Vinukonda, E. R., & Jagadesh, B. N. (2024) propusieron un modelo de deep learning integrado para diagnóstico temprano y multi-clase de Alzheimer a partir de MRI, enfatizando la utilidad de estas herramientas en la práctica clínica para detección y seguimiento.

Estos estudios destacan la creciente integración de inteligencia artificial, aprendizaje profundo y análisis multimodal en el diagnóstico y seguimiento del Alzheimer, sentando las bases para el desarrollo de aplicaciones móviles que permitan la detección temprana, seguimiento evolutivo y comunicación efectiva entre médicos, pacientes y familiares, tal como se propone en el presente proyecto.

## III. METODOLOGÍA

### A. Nivel de Investigación

Se determinó que el presente trabajo de investigación partiera de un **nivel descriptivo**, esto de acuerdo con la definición planteada por Guevara et al. (2020), quienes la caracterizan como aquella enfocada en la recolección de información observable y verificable, permitiendo posteriormente un análisis riguroso mediante un marco teórico adecuado que facilite establecer relaciones válidas entre los datos obtenidos.

Estas características resultan esenciales para el desarrollo de este proyecto, debido a que la base principal para la construcción del modelo predictivo asistido por inteligencia artificial radica en la confiabilidad y consistencia de la información procesada, en este caso imágenes médicas MRI asociadas al deterioro cognitivo y marcadores del Alzheimer. Este nivel metodológico permite analizar el comportamiento y los patrones presentes en dichas imágenes sin alterar los datos originales, garantizando así un proceso de evaluación objetivo y no intervencionista.

## B. Nivel de Investigación

Dado que la investigación se encuentra en la intersección entre los campos de la ingeniería de software, inteligencia artificial y ciencias médicas, se optó por un enfoque de investigación transversal. Tal como lo plantean Corona y Fonseca (2023), un estudio transversal permite realizar un análisis en un momento determinado, finalizando con una única evaluación dentro de un periodo predefinido, lo cual resulta pertinente en investigaciones orientadas al análisis diagnóstico en salud.

En concordancia con lo anterior, el enfoque transversal aplicado en este proyecto permitirá estudiar la experiencia y percepción de los usuarios (médicos y estudiantes de medicina) durante una etapa concreta de interacción con el prototipo móvil, facilitando la evaluación de su utilidad clínica, usabilidad y eficiencia del procesamiento IA durante el análisis de imágenes MRI para la detección temprana del Alzheimer.

## C. Diseño de Investigación

El diseño metodológico seleccionado fue experimental, dado que permitirá evaluar el efecto de la variable independiente sobre la variable dependiente bajo escenarios controlados. Siguiendo lo señalado por Ramos (2021), este diseño es adecuado en estudios donde se requiere comprobar la eficacia de una herramienta tecnológica mediante comparación y observación controlada.

En el contexto del presente proyecto, la variable independiente corresponde al uso de la aplicación móvil asistida por IA para el análisis de imágenes MRI, mientras que la variable dependiente está representada por la precisión percibida en los resultados, la usabilidad del sistema y la eficiencia en la interacción del usuario.

El diseño experimental permitirá medir el impacto del prototipo en situaciones específicas previamente definidas, evaluando la interacción con el flujo de procesamiento diagnóstico y determinando si la aplicación aporta una mejora significativa como herramienta de apoyo clínico

## D. Población y Muestra

### 1) Población de Estudio

Para la presente investigación se consideró como población objetivo a personas adultas que se encuentran dentro del rango etario asociado al riesgo temprano y mediano de deterioro cognitivo. Específicamente, se incluyeron hombres y mujeres entre 50 y 75 años, rango sugerido en estudios clínicos por corresponder a una etapa en la cual comienzan a manifestarse los primeros signos detectables de Alzheimer, tanto estructurales como cognitivos (Wang et al., 2024; You et al., 2022).

Se excluyeron personas menores de 50 años, dado que la prevalencia estadística del Alzheimer temprano es significativamente baja y podría introducir sesgos irrelevantes en las pruebas del prototipo. Asimismo, no se consideraron individuos con diagnóstico previo confirmado, ya que el objetivo del estudio es validar la herramienta como apoyo temprano para evaluación y seguimiento, no como medio directo de diagnóstico formal.

### 2) Muestra Poblacional

Partiendo de una población muy general y por ello numerosa, es necesario trabajar con una muestra aún más reducida, tanto a nivel cuantitativo como local; es entonces, que la muestra se definió con 100 personas residentes en el departamento de Lima, que están en el rango de edad de la adultez. Esta selección evidentemente traerá ciertas limitaciones en términos de representatividad, pero al tratarse de recopilar los datos necesarios para establecer un modelo web a nivel nacional, sirve como una base inicial que podrá permitir el logro un mayor alcance a futuro.

### 3) Instrumentos de Recolección de Datos:

Para la recolección de información se emplearon métodos mixtos cuantitativos y cualitativos orientados a asegurar la precisión diagnóstica del modelo predictivo y la facilidad de uso del sistema. Los instrumentos utilizados fueron:

- Encuestas digitales estructuradas, distribuidas mediante aplicación móvil y web, con escalas Likert para medir experiencia de usuario, comprensión del resultado y percepción de utilidad.
- Cuestionarios estandarizados cognitivos, tales como Mini-Mental State Examination (MMSE) y Montreal Cognitive Assessment (MoCA), con el objetivo de correlacionar los resultados del modelo IA con indicadores clínicos conocidos.
- Entrevistas semiestructuradas dirigidas a especialistas en neurología y profesionales de la salud para validar interpretaciones, legibilidad diagnóstica y pertinencia del sistema en contextos clínicos reales.
- Registros automáticos del sistema (logs) para medir patrones de uso, errores, tiempos de interacción y precisión del algoritmo.

El uso de estos instrumentos se complementó con la aplicación de la metodología Design Thinking, permitiendo realizar mejoras incrementales basadas en comentarios reales de usuarios, especialistas y cuidadores.

#### IV. METODOLOGIA: DESIGN THINKING

El proceso se desarrolló en cinco etapas iterativas:

**1. Empatizar:** La primera etapa del proceso de Design Thinking, aplicada al desarrollo del aplicativo móvil para la segmentación y clasificación del Alzheimer, tuvo como objetivo comprender de manera profunda las necesidades, dificultades y experiencias de los usuarios potenciales, con el fin de diseñar una aplicación que facilite el diagnóstico, comprensión y seguimiento de la enfermedad mediante inteligencia artificial (IA). Los usuarios clave incluyen médicos neurólogos, estudiantes de medicina, pacientes y familiares de personas con Alzheimer (Aghili, Tabarestani, Adjouadi, & Adeli, 2018; Bootun et al., 2025).

Para esta fase se utilizaron diversas técnicas de investigación que permitieron recopilar información cualitativa y cuantitativa sobre los usuarios:

a) Entrevistas personales  
Se realizaron entrevistas a tres médicos neurólogos y tres estudiantes de medicina de último año, con el propósito de explorar su experiencia profesional, los procesos de diagnóstico que emplean y las limitaciones que enfrentan al momento de detectar y clasificar el Alzheimer. Asimismo, se entrevistó a tres pacientes diagnosticados en etapas leve y moderada, y a cinco familiares o cuidadores principales, incluyendo hijos, cónyuges y hermanos, para comprender su percepción del diagnóstico, el tipo de apoyo recibido y su disposición hacia el uso de herramientas digitales médicas (Morra et al., 2019; Liu, Liu, Cai, & Che, 2020).

Durante las entrevistas se indagó sobre los métodos actuales de diagnóstico, como pruebas cognitivas, resonancias magnéticas (MRI), PET, biomarcadores y entrevistas clínicas. Los participantes destacaron ventajas y limitaciones de los métodos tradicionales: si bien los médicos valoran la precisión y la combinación de evaluaciones clínicas con imágenes, mencionaron problemas como alto costo, tiempo prolongado y complejidad de interpretación. Los estudiantes señalaron la dificultad para correlacionar síntomas con imágenes y la necesidad de guías visuales y apoyo mediante IA para la detección temprana de Alzheimer.

Además, se exploró la experiencia en el manejo de imágenes médicas, identificando que los profesionales enfrentan dificultades para diferenciar atrofia normal de patológica y para comparar estudios previos. Las regiones críticas más mencionadas fueron el hipocampo, la corteza temporal y los ventrículos laterales. En cuanto a herramientas, se emplean software como OsiriX, RadiAnt, PACS, 3D Slicer y MRICron, aunque los participantes señalaron la necesidad de mejoras en precisión, rapidez y visualización, incluyendo segmentación automática y mapas de calor (Vinukonda & Jagadesh, 2024; Jumaili & Sonuç, 2025).

b) Exploración de percepción sobre IA  
Se abordó la percepción y aceptación de sistemas basados en inteligencia artificial para apoyar el diagnóstico. Médicos y estudiantes manifestaron expectativas sobre beneficios como rapidez, detección temprana, segmentación automática y predicción de progresión, aunque expresaron preocupaciones relacionadas con malinterpretación, privacidad y dependencia tecnológica. Los participantes coincidieron en la preferencia por la presentación de resultados mediante mapas de calor, gráficas interpretativas y la posibilidad de exportar informes en PDF para integrar al historial clínico (Shaffi et al., 2024; Islam & Alyasiri, 2019).

c) Entrevistas a pacientes y familiares  
Para los pacientes y sus cuidadores, se buscó comprender su experiencia frente al diagnóstico, el nivel de comprensión de la información médica y las necesidades de apoyo emocional, educativo y médico. Se identificó que la mayoría de los pacientes y familiares experimentan miedo, incertidumbre y ansiedad al recibir el diagnóstico. Destacaron la necesidad de explicaciones simplificadas, recursos visuales y seguimiento continuo, así como confianza en la tecnología cuando está respaldada por profesionales médicos. También se evaluó la accesibilidad tecnológica y la disposición para interactuar con aplicaciones médicas basadas en IA, revelando que los dispositivos más usados son celulares y tabletas, y que las barreras principales incluyen comprensión de resultados, privacidad y ansiedad emocional (You et al., 2022; Nan et al., 2022).

d) Sintetizando a través del Mapa de empatía  
Como resultado de la información recabada mediante entrevistas y encuestas, se elaboró un mapa de empatía para representar los principales hallazgos sobre las percepciones, emociones y comportamientos de los usuarios frente al uso de una aplicación médica basada en IA (Sangeetha & Nair, 2023; Nour, Senturk, & Polat, 2024).

El análisis reveló que los médicos y estudiantes buscan precisión, automatización y soporte visual sin perder el control clínico, mientras que pacientes y familiares priorizan comprensión, accesibilidad, apoyo emocional y comunicación clara. Ambos grupos coincidieron en la necesidad de herramientas integradas, visuales y confiables, que permitan un diagnóstico más eficiente y un seguimiento seguro del paciente. Asimismo, se identificaron zonas de dolor relacionadas con la lentitud de los procesos, la interpretación subjetiva, la complejidad tecnológica y la ansiedad ante resultados, así como expectativas de obtener rapidez, claridad y confiabilidad en la información generada (Dakshinamoorthy et al., 2025; Morra et al., 2019).

**Tabla 1.** Mapa de empatía

Dimensión	Médicos y Estudiantes	Pacientes y Familiares	
¿Qué piensan y sienten?	Se preocupan por la exactitud del diagnóstico y la responsabilidad médica. Desean reducir el margen de error y mejorar la detección temprana. Perciben que los métodos actuales son lentos y costosos. Buscan innovación, pero sin perder control clínico.	Sienten miedo, incertidumbre y ansiedad al recibir el diagnóstico. Buscan comprensión, esperanza y apoyo. Los familiares desean estar mejor informados y tener control del progreso del paciente.	tecnologías e inteligencia artificial, pero con dudas sobre su precisión y ética. También oyen de pacientes que los procesos son lentos y confusos.
¿Qué ven?	Ven sistemas médicos fragmentados, falta de integración entre datos clínicos e imágenes, y escasez de herramientas accesibles. Observan que el diagnóstico depende demasiado del criterio del especialista.	Ven procesos médicos complejos, lenguaje técnico y falta de seguimiento constante. Perciben que la atención depende del tiempo del médico y que hay poca comunicación continua.	Procesos diagnósticos largos, interpretación subjetiva, alto costo de pruebas, sobrecarga de trabajo y falta de integración de datos clínicos. Temor a depender demasiado de la IA o a errores automáticos.
¿Qué dicen y hacen?	Expresan la necesidad de apoyo tecnológico confiable y visual. Usan MRI, pruebas cognitivas y software limitado. Los estudiantes buscan herramientas educativas que expliquen patrones visuales.	Expresan confusión al recibir información médica. Piden explicaciones simples, apoyo emocional y herramientas visuales. Los cuidadores buscan recursos prácticos para el día a día.	Resultados esperados (Ganancias)
¿Qué escuchan?	Escuchan de colegas sobre nuevas	Escuchan consejos médicos difíciles de	Herramienta que integre imágenes y datos clínicos, ofrezca segmentación automática y mapas de calor interpretativos. Mayor rapidez, precisión y soporte visual que complemente el juicio médico.

**2. Definir:** A partir de la información recopilada durante la fase de empatía, se pudo identificar el problema central que enfrentan los usuarios clave en el diagnóstico del Alzheimer: médicos especialistas y familiares de pacientes requieren una herramienta simple, confiable y asistida por inteligencia artificial (IA) que permita subir, analizar y visualizar imágenes cerebrales (MRI), con el objetivo de detectar signos tempranos de Alzheimer, reducir los tiempos de diagnóstico y garantizar interpretaciones precisas y comprensibles (Aghili, Tabarestani, Adjouadi & Adeli, 2018; Vinukonda & Jagadesh, 2024; Bootun et al., 2025).

En el caso de los médicos, se identificó la necesidad de agilizar el análisis e interpretación de imágenes mediante IA, obtener resultados visuales y cuantificables —como mapas de calor, segmentación de regiones afectadas y reportes en PDF— y contar con un sistema seguro, validado científicamente y compatible con los flujos clínicos existentes (Liu, Liu, Cai & Che, 2020; Morra et al., 2019; Jumaili & Sonuç, 2025). Por su parte, pacientes y familiares requieren recibir resultados explicados en lenguaje claro y visual, comprender las recomendaciones médicas y sentir confianza en el manejo de sus datos personales y resultados clínicos (Sangeetha & Nair, 2023; Nour, Senturk & Polat, 2024; Dakshinamoorthy et al., 2025).

Para representar a los usuarios de manera concreta, se elaboraron user personas. Por ejemplo, el Dr. Luis Herrera, neurólogo de 42 años, busca reducir el tiempo de análisis de estudios cerebrales y mejorar la precisión diagnóstica; enfrenta frustraciones como procesos lentos y dificultad para interpretar imágenes y explicar resultados a pacientes. Por otro lado, Rosa Gutiérrez, de 58 años y cuidadora principal de su madre con Alzheimer inicial, necesita comprender los resultados médicos y recibir orientación práctica, enfrentando dificultades con terminología confusa y miedo a malinterpretar la información (Ibáñez et al., 2012; Islam & Alyasiri, 2019).

El insight clave indica que los médicos buscan precisión, respaldo técnico y eficiencia, mientras que los pacientes y familiares requieren claridad, empatía y orientación emocional. La aplicación debe conectar ambos mundos, combinando rigurosidad clínica con simplicidad comunicativa, fortaleciendo así la confianza y comprensión del diagnóstico (Shaffi et al., 2024; Nan et al., 2022).

**3. Idear:** En esta etapa del proceso de Design Thinking, el objetivo principal fue generar la mayor cantidad posible de ideas que respondieran a las preguntas “How Might We...” (¿Cómo podríamos?) formuladas a partir de los insights y necesidades identificadas en la etapa de Definir. El propósito fue proponer soluciones innovadoras, viables y centradas en el usuario, que orienten el diseño del prototipo funcional del aplicativo móvil para el diagnóstico asistido del Alzheimer mediante inteligencia artificial (IA) (Aghili, Tabarestani, Adjouadi & Adeli, 2018; Vinukonda & Jagadesh, 2024).

Se aplicaron técnicas de ideación colaborativa, incluyendo lluvia de ideas (brainstorming) y SCAMPER, que permiten explorar soluciones diversas, creativas y disruptivas, fomentando la innovación dentro de los límites de viabilidad técnica y clínica (Bootun et al., 2025; Liu, Liu, Cai & Che, 2020).

Preguntas “How Might We...” (¿Cómo podríamos?)

- ¿Cómo podríamos facilitar que los médicos diagnostiquen el Alzheimer de forma más rápida y

precisa mediante IA, sin reemplazar su criterio clínico?

- ¿Cómo podríamos permitir que los pacientes y familiares comprendan fácilmente los resultados médicos a través de visualizaciones claras y lenguaje accesible?
- ¿Cómo podríamos garantizar la privacidad y seguridad de las imágenes cerebrales sin afectar la facilidad de uso de la aplicación?
- ¿Cómo podríamos integrar el seguimiento de la evolución del paciente y la comparación entre estudios previos dentro del mismo entorno digital?
- ¿Cómo podríamos aumentar la confianza del médico en los resultados generados por IA a través de reportes validados científicamente y visualmente interpretables?
- ¿Cómo podríamos ofrecer orientación práctica y emocional a los familiares tras la detección de signos tempranos de Alzheimer?

Técnicas utilizadas:

Lluvia de ideas (Brainstorming)

Se realizó una sesión grupal enfocada en generar la mayor cantidad de soluciones posibles, priorizando aquellas que mejor respondían a los retos planteados en las preguntas “How Might We”.

Tabla 2. Ideas generadas

1	Panel médico con carga directa de MRI y análisis automático mediante IA.
2	Mapas de calor interactivos que muestran la progresión del Alzheimer en diferentes regiones cerebrales.
3	Reporte dual (versión técnica para médicos y versión simplificada para familiares).
4	Sistema de seguimiento evolutivo con alertas visuales y gráficas comparativas.
5	Módulo educativo con ejercicios cognitivos y recomendaciones personalizadas.
6	Validación científica integrada (indicando precisión, modelo IA utilizado y bibliografía médica de referencia).
7	Control de privacidad con consentimiento informado digital y cifrado de datos.

SCAMPER: Se aplicó la técnica SCAMPER para modificar y mejorar ideas existentes, explorando sustituciones, combinaciones, adaptaciones, modificaciones, potenciación de usos, eliminación de barreras y reorganización de procesos (Ortiz, Fernández & Li, 2022).

**Tabla 3.** Técnica SCAMPER

Letra	Acción	Aplicación en el proyecto
S	Sustituir	Procesos manuales de interpretación de imágenes por análisis automatizado con IA. Reducción de tiempo y error humano.
C	Combinar	Integrar análisis de imágenes, reportes y comunicación médico-paciente. Plataforma todo en uno.
A	Adaptar	Adaptar modelos de visión computacional a datos clínicos locales. Mayor precisión y contextualización.
M	Modificar	Simplificar la visualización de resultados para pacientes con lenguaje claro. Accesibilidad y comprensión emocional.
P	Poner en otros usos	Usar el análisis IA también para seguimiento y evolución del Alzheimer. Monitoreo longitudinal.
E	Eliminar	Eliminar la necesidad de múltiples plataformas y procesos lentos. Flujo optimizado y unificado.
R	Reorganizar	Reordenar la experiencia de usuario para que el flujo médico-paciente sea fluido y empático. Comunicación más efectiva.

#### Matriz de Priorización (Impacto vs. Esfuerzo)

Las ideas generadas fueron evaluadas según su impacto potencial en la experiencia del usuario y en la eficiencia clínica versus el esfuerzo de implementación técnica. Esta matriz permitió identificar soluciones de alto impacto y factibilidad inmediata, priorizando funciones como el panel médico con análisis IA, mapas de calor interactivos y reportes duales, mientras que módulos complementarios como ejercicios cognitivos o alertas avanzadas fueron planificados para fases posteriores del prototipo (Aghili, Tabarestani, Adjouadi, & Adeli, 2018; Bootun et al., 2025).

**Tabla 4.** Funcionalidades

Funcionalidad / Idea		Impacto	Esfuerzo	Prioridad
Procesamiento automático con IA		Alto	Alto	Alta
Resultados duales (médico y simplificado)		Alto	Medio	Alta
Exportación a PDF		Medio	Bajo	Alta
Notificaciones y recordatorios		Medio	Bajo	Media
Historial de análisis y evolución		Alto	Medio	Media
Registro/Login seguro		Alto	Bajo	Alta
Recomendaciones personalizadas		Alto	Medio	Media
Interfaz de soporte / ayuda		Medio	Bajo	Media

La etapa de ideación permitió consolidar un conjunto de funcionalidades de alto valor clínico y humano, priorizando aquellas que maximizan el impacto en la experiencia del usuario médico y del paciente. El resultado es una solución digital integral, capaz de combinar análisis automatizado, comunicación empática, creando una herramienta innovadora para el diagnóstico y seguimiento del Alzheimer.

**4. Prototipar:** El prototipo desarrollado tiene como objetivo

representar la experiencia de usuario tanto para médicos especialistas como para pacientes y familiares, simulando la interacción completa con la aplicación móvil para el diagnóstico asistido de Alzheimer mediante inteligencia artificial (IA). Este prototipo funcional e interactivo contempla todo el flujo del usuario, incluyendo el acceso seguro, la carga y procesamiento automático de imágenes cerebrales mediante IA, la visualización de resultados con interpretación técnica para médicos y versión simplificada para pacientes y familiares, la edición de datos de pacientes y el envío de resultados, así como la generación de un historial de evolución que permite comparar estudios previos y evaluar la progresión de la enfermedad.

Diseño funcional: El prototipo presenta una interfaz limpia, con jerarquía visual clara y lenguaje accesible, diferenciando la vista médica (detallada) de la vista para pacientes y familiares (simplificada). Se incorporan mapas de calor y gráficos que muestran áreas afectadas y evolución del Alzheimer, así como funciones exportables y compartibles en PDF. El acceso está asegurado mediante un sistema de registro y autenticación para usuarios médicos, garantizando la privacidad y seguridad de los datos.

Prototipo en Figma: Se desarrolló un prototipo interactivo en Figma que simula la navegación real dentro de la aplicación. Este incluye transiciones entre módulos, botones funcionales, formularios de registro y carga de imágenes, así como vistas de análisis y del historial clínico. Además, se integraron elementos visuales como mapas de calor, gráficos evolutivos y botones de acción rápida, tales como “descargar PDF” o “enviar resultados vía email”, con el fin de mejorar la usabilidad y la experiencia del usuario.

**Tabla 5.** Componentes claves del prototipo

Módulo	Descripción funcional	Pantalla / Funcionalidad
Inicio de sesión / Registro médico	Autenticación segura y registro de nuevos médicos.	Pantalla: Login/Registro. Funcionalidad: Ingreso con correo y contraseña, registro de médico nuevo con nombre, apellido, usuario y contraseña.
Panel principal / Dashboard	Vista general del sistema con acceso a funciones clave.	Pantalla: Dashboard principal. Funcionalidad: Lista de pacientes, botón “Registrar paciente”, estadísticas de análisis realizados.
Gestión de pacientes	Registro, selección y edición de pacientes.	Pantalla: Lista de pacientes. Funcionalidad: Selección de paciente, registro de nuevo paciente, edición de datos personales y clínicos, búsqueda y filtrado.
Registro / edición de paciente	Formulario de ingreso de datos y antecedentes clínicos.	Pantalla: Formulario paciente. Funcionalidad: Nombre, edad, teléfono, contacto familiar, antecedentes clínicos relacionados con Alzheimer, guardar cambios.
Carga de imágenes cerebrales	Subida de MRI para procesamiento automático.	Pantalla: Upload MRI. Funcionalidad: Selección de imágenes desde dispositivo móvil, verificación de calidad automática, envío al modelo IA.
Análisis y resultados	Visualización de resultados del análisis de IA.	Pantalla: Resultado análisis. Funcionalidad: Mapa de calor con áreas afectadas, clasificación de Alzheimer (leve, moderado, severo), interpretación médica y versión simplificada, exportación PDF.
Historial clínico	Registro de todos los análisis y evolución del paciente.	Pantalla: Historial paciente. Funcionalidad: Consulta de estudios anteriores, comparación de resultados, gráficas evolutivas de deterioro o mejora cognitiva.
Envío de resultados	Comunicación con paciente/familiar.	Pantalla: Compartir informe. Funcionalidad: Exportar PDF, enviar por correo, registrar confirmación de envío.
Configuración / Perfil médico	Gestión de datos y preferencias del médico.	Pantalla: Perfil médico. Funcionalidad: Editar información personal, cambiar contraseña, configurar notificaciones.



Prototipos de la aplicación:

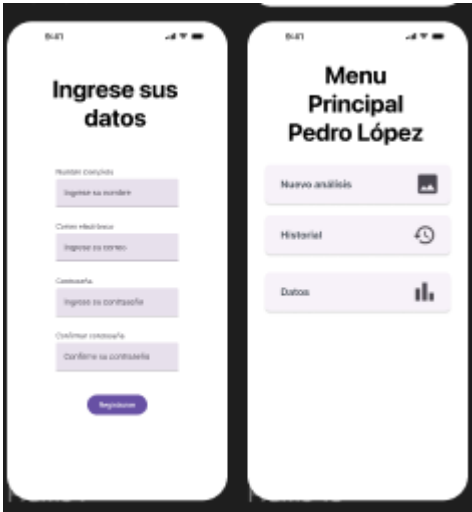


Fig. 1: Pantalla Login Fig.2: Menú principal



Fig. 3: Cargar pantalla Fig. 4: Resultados

5. **Testear:** La fase de testeo tuvo como objetivo validar la funcionalidad, usabilidad y utilidad del prototipo interactivo de la aplicación móvil para el diagnóstico asistido del Alzheimer mediante inteligencia artificial (IA), considerando tanto la experiencia de los médicos especialistas como la de los estudiantes de medicina. Esta etapa permitió recopilar retroalimentación directa sobre la experiencia de navegación, la comprensión de los módulos, la visualización de resultados y el manejo del historial clínico, proporcionando información valiosa para realizar ajustes antes del desarrollo e implementación final.

Resultados esperados:

- Validar la navegación general de la aplicación y la comprensión del flujo de uso por parte de los usuarios.
- Evaluar la facilidad para registrar pacientes, cargar imágenes cerebrales y recibir análisis automáticos mediante IA.
- Comprobar la claridad en la presentación de resultados, incluyendo mapas de calor, clasificación del Alzheimer, interpretaciones médicas y versiones simplificadas para familiares.
- Evaluar la funcionalidad de exportación de informes en PDF y la comunicación con pacientes/familiares.
- Identificar oportunidades de mejora en términos de funcionalidad, usabilidad y diseño.

Usuarios participantes:

- 3 médicos especialistas en neurología.
- 3 estudiantes de medicina de último año.

Tabla 6. Prototipos testeados y objetivos

Módulo	Pantalla	Objetivo de la prueba
Registro de médico	de	Validar la comprensión del proceso de registro y autenticación segura.
Login médico		Comprobar facilidad para acceder a la cuenta existente.
Registro y edición de pacientes	y de	Evaluar claridad en el ingreso de datos clínicos, contacto familiar y edición de información.
Selección de paciente y carga de MRI	de	Verificar facilidad para seleccionar paciente registrado y subir imágenes cerebrales.
Resultados de análisis de IA	de	Evaluar comprensión de mapas de calor, clasificación de Alzheimer y versión simplificada para paciente/familiar.

Exportación y envío de resultados Comprobar funcionalidad para generar PDF y enviar a familiar o paciente.

Historial clínico Validar visualización de evolución del paciente y comparación con análisis previos.

#### Método de prueba:

Se realizaron pruebas directas con el prototipo, registrando respuestas y observaciones en hojas de Excel. Cada participante recorrió el flujo completo, desde el registro hasta la consulta del historial clínico y el envío de resultados.

**Tabla 7.** Resultados cuantitativos

Métrica evaluada	Resultado (%)
Facilidad de navegación	100% de los participantes pudo moverse entre módulos sin confusión.
Comprensión del flujo de registro y login	100% comprendió cómo registrarse o iniciar sesión.
Registro y edición de pacientes	83% encontró intuitivo el ingreso de datos; 17% necesitó aclaración sobre campos clínicos.
Carga de imágenes y procesamiento IA	100% pudo subir imágenes y obtener resultados.
Interpretación de resultados	83% comprendió claramente mapa de calor y clasificación; 17% pidió aclaraciones sobre algunos términos técnicos.
Visualización de informe simplificado	100% encontró la versión simplificada comprensible para pacientes/familiares.
Exportación de PDF	100% logró exportar y preparar el envío de resultados.
Historial y seguimiento	83% comprendió la evolución temporal; 17% sugirió mejorar la visualización de comparaciones gráficas.

#### Retroalimentación cualitativa:

- Médico 1: “Muy claro el flujo de carga de MRI y los mapas de calor. Sugiero etiquetas más grandes en las zonas afectadas.”
- Médico 2: “La versión simplificada para familiares es útil. Sería bueno agregar recomendaciones más detalladas según el nivel de afectación.”
- Médico 3: “Todo correcto, aunque en la sección de historial la comparación de estudios podría ser más visual.”
- Estudiante 1: “Comprendí fácilmente los resultados médicos, pero me costó entender los porcentajes de probabilidad en el mapa de calor.”
- Estudiante 2: “El flujo es intuitivo. Tal vez se podría agregar un tutorial rápido al inicio.”
- Estudiante 3: “Me gustó la opción de enviar PDF al familiar, pero sería útil que se indique cuándo el paciente recibió el informe.”

**Tabla 8.** Mejoras implementadas a partir de las pruebas:

Sugerencias de los usuarios	Mejoras realizadas
Mejorar visualización de áreas afectadas en mapa de calor	Se aumentó el tamaño de las etiquetas y se añadieron colores más contrastantes para identificar zonas críticas.
Agregar recomendaciones más personalizadas según nivel de afectación	Se incorporaron consejos de hábitos saludables y ejercicios cognitivos por nivel (leve, moderado, severo).
Mejorar visualización del historial clínico	Se añadieron gráficas comparativas y barras de progreso para evolución temporal del paciente.
Facilitar comprensión de porcentajes en mapas de calor	Se añadieron leyendas explicativas y etiquetas de probabilidad con lenguaje más claro.
Incluir tutorial inicial para nuevos usuarios	Se implementó guía rápida interactiva al primer inicio de sesión.

Confirmación de recepción del informe por paciente/familiar de Se añadió notificación en el panel médico indicando si el PDF fue recibido o descargado.

para predicción de Alzheimer

## V. METODOLOGIA: SCRUM

### A. Planification

Para llevar a cabo el desarrollo del sistema predictivo móvil para detección temprana del Alzheimer mediante imágenes cerebrales, se seleccionó la metodología ágil SCRUM, debido a su capacidad para organizar el trabajo en entregas parciales y funcionales, mejorar la comunicación del equipo y permitir ajustes progresivos.

Según Tymkiw et al. (2020), SCRUM puede aplicarse en entornos académicos para fortalecer las habilidades de trabajo colaborativo, planificación y aplicación de procesos propios del desarrollo de software. Bajo este enfoque, el proyecto se estructuró con roles definidos, reuniones periódicas y planificación por *sprints*, asegurando un avance iterativo, demostrable y medible.

### B. Product Backlog

El **Product Backlog** representa la lista priorizada de funcionalidades, mejoras técnicas y requerimientos necesarios para lograr una implementación completa del sistema móvil de detección de Alzheimer. Este incluye elementos relacionados con autenticación de usuarios, almacenamiento de datos clínicos, cargado y procesamiento de imágenes MRI, ejecución del modelo de inteligencia artificial y visualización de resultados predictivos.

**Tabla 9.** Product Backlog del Sistema

ID	Tipo	Descripción	Prioridad	Puntos
PB01	Infraestructura	Configuración de Flutter + entorno Flask con conexión a Firestore	Alta	5
PB02	Autenticación	Sistema de login/registro con roles (paciente/médico)	Alta	8
PB03	IA	Integración del modelo TensorFlow Lite	Alta	8

PB04	API REST	Implementación de endpoints para subir imágenes y obtener predicción	Alta	5
PB05	Procesamiento	Preprocesamiento de imágenes MRI antes de la inferencia	Alta	5
PB06	Front end Login	Pantalla de acceso con validación	Alta	3
PB07	Front end Registro	Pantalla de registro del usuario	Alta	5
PB08	Diagnóstico	Pantalla para cargar imagen y solicitar predicción	Alta	8
PB09	Resultados	Vista de resultados con interpretación del modelo y confianza	Alta	5
PB10	Historial	Panel del usuario con historial de diagnósticos	Media	5
PB11	Panel Médico	Vista de gestión de pacientes para profesionales de salud	Media	8
PB12	Perfil	Configuración y edición de datos personales	Media	3
PB13	UI/UX	Mejoras visuales y consistencia de estilos	Baja	3
PB14	Seguridad	Validación de datos, verificación de usuario y cifrado	Alta	5

### C. Diagrama de Proyecto

La Figura correspondiente presenta la arquitectura final del sistema, compuesto por una aplicación móvil desarrollada en Flutter como interfaz de usuario, que se comunica con un servidor backend programado en Flask mediante una API REST.

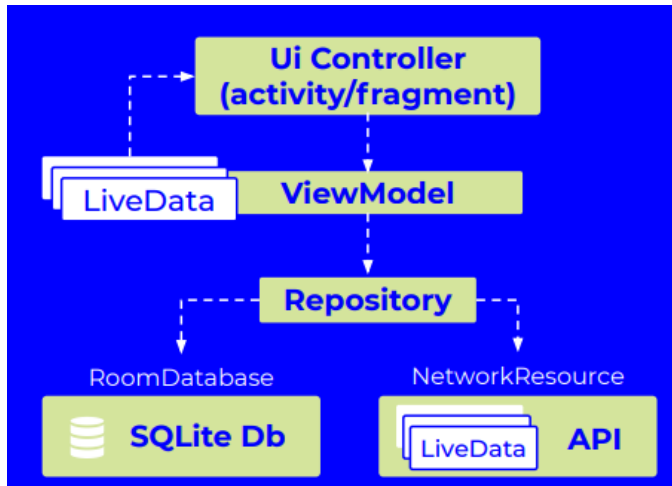


Fig. 5. Diagrama MVVC Proyecto

El backend administra usuarios, recibe las imágenes MRI, ejecuta el modelo predictivo optimizado en TensorFlow Lite y retorna los resultados para su visualización. La arquitectura sigue el patrón MVC, permitiendo una separación clara entre la lógica del negocio, presentación y control.

### D. Planificación de los Sprints

El desarrollo del sistema se organizó en **cuatro sprints principales**, estructurados para entregar componentes funcionales al finalizar cada ciclo. Cada sprint incluyó: análisis, diseño, implementación, pruebas internas y documentación del avance, garantizando la evolución continua del sistema hacia su versión final.

Tabla 10. Sprint 1 – Base técnica y autenticación

ID	Descripción	Puntos
PB01	Configuración del entorno Flutter + Flask	5
PB02	Login y registro de usuario	8
PB04	Implementación básica de API	5

PB06	Pantalla de inicio de sesión	3
<b>Total estimado</b>		<b>21</b>

Tabla 11. Sprint 2 – Integración del modelo IA y diagnóstico

ID	Descripción	Puntos
PB03	Integración del modelo TFLite	8
PB05	Preprocesamiento de imágenes	5
PB08	Pantalla de diagnóstico	8
PB09	Pantalla de resultados	5
<b>Total estimado</b>		<b>26</b>

Tabla 12. Sprint 3 – Módulos avanzados

ID	Descripción	Puntos
PB10	Historial de diagnósticos	5
PB11	Panel para médicos	8
PB12	Edición de perfil	3
PB14	Seguridad avanzada	5
<b>Total estimado</b>		<b>21</b>

**Tabla 13.** Sprint 4 – Optimización y despliegue

ID	Descripción	Puntos
PB13	Mejoras UI/UX	3
PB07	Ajustes finales de registro y validaciones	5
Deploy	Publicación del sistema	5
Testing	Pruebas finales y documentación	8
<b>Total estimado</b>		<b>21</b>

#### E. Descripción General del Sistema

El sistema desarrollado corresponde a una aplicación móvil que permite cargar imágenes cerebrales (MRI) provenientes del paciente y procesarlas mediante un modelo de aprendizaje profundo, con el fin de identificar probables signos tempranos de Alzheimer.

Su estructura se divide en dos componentes fundamentales:

- Frontend móvil (Flutter): permite la interacción con el usuario, gestión de cuenta, carga de imágenes y visualización de resultados.
- Backend (Flask): administra datos, procesa solicitudes, ejecuta el modelo predictivo en formato TensorFlow Lite y genera reportes.

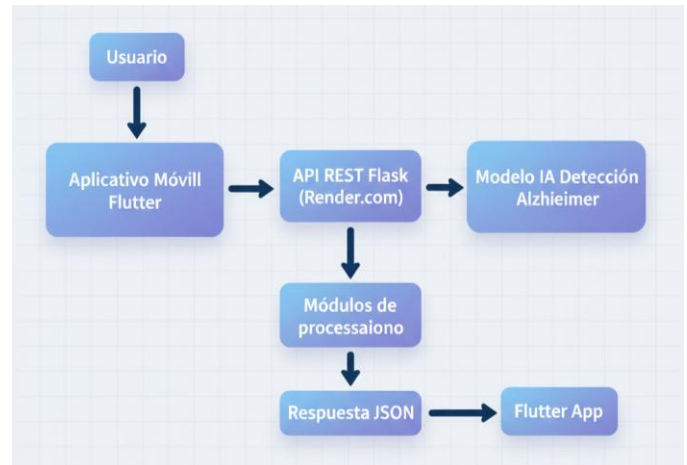
Esta arquitectura asegura portabilidad, eficiencia computacional y escalabilidad futura.

#### F. Arquitectura General

El sistema se construyó siguiendo un modelo cliente-servidor. La aplicación móvil consume los servicios del backend mediante solicitudes HTTPS utilizando librerías como Dio/HTTP.

El modelo de inteligencias artificial se integró en formato .tflite, permitiendo un procesamiento más rápido y adecuado para entornos móviles. Dentro del backend, el patrón MVVC

organiza controladores, servicios y acceso a la base de datos, alcanzando una implementación estructurada y mantenible.




**Fig 6.** Arquitectura de la aplicación

#### G. Componentes del Backend

Los módulos principales del backend incluyen:

- Controladores: encargados de gestionar solicitudes (autenticación, diagnóstico y registros).
- Modelos: responsables del manejo de los datos del usuario, imágenes, historial y resultados.
- Modelo IA: archivo **.tflite** que contiene la red neuronal convolucional diseñada para procesar imágenes cerebrales y estimar probabilidad de Alzheimer.



**Fig 7.** Análisis de precisión del modelo

#### H. Componentes del Frontend

La interfaz móvil fue desarrollada en **Flutter**, estructurada en vistas y componentes reutilizables. Las principales pantallas incluyen:

- Inicio de sesión y registro
- Carga de imágenes MRI
- Visualización de predicciones y mapas de calor
- Historial clínico del paciente

- Panel médico (según rol)

El diseño se centró en la accesibilidad, claridad y usabilidad para médicos, cuidadores y estudiantes en formación clínica.

### I. Flujo de Funcionalidad

- 1) El usuario accede a la plataforma y se autentica mediante el sistema de login.
- 2) Tras autenticarse, puede iniciar un diagnóstico ingresando información clínica.
- 3) El backend procesa esta información mediante el modelo *modeloDEC.tflite* y almacena el resultado.
- 4) El usuario visualiza el resultado desde la interfaz en *Resultados.jsx*.
- 5) Un usuario con rol administrativo puede acceder a estadísticas y realizar gestiones desde el panel de administración.

### J. Base de Datos y Almacenamiento

Se empleó PostgreSQL para elaborar una base de datos sencilla y efectiva para el propósito del proyecto, *psycopg2*.

Esta base de datos almacenará los datos generales de cada usuario, así como sus diagnósticos y resultados, además de otras configuraciones adicionales del sistema.



Fig 8. Diagrama modelo de Base de Datos

## VI. DISCUSIÓN RESULTADOS

Los resultados de la investigación se presentan a partir de la validación exploratoria del prototipo funcional construido a partir de metodologías ágiles y centradas en el usuario. Para su validación se utilizaron instrumentos como entrevistas semiestructuradas, encuestas digitales y pruebas internas de interacción para determinar la aceptación, utilidad percibida y usabilidad del sistema.

### A. Validación del prototipo funcional

1) *Efectividad observada:* Durante la primera ronda de pruebas internas realizadas con usuarios de diferentes grupos de edad (adultos jóvenes, intermedios, mayores), se estuvo a la vista y se completó sin grandes dificultades por la mayoría de los usuarios el formulario digital adaptado para el diagnóstico. El hecho de representar el riesgo cardiovascular a través de un sistema de semáforo (verde, amarillo, rojo) fue intuitivo y facilitó la interpretación de resultados. Aunque no se controlaron métricas temporales, los usuarios que participaron pudieron completar el flujo de uso completo registro, entrada de datos, diagnóstico y lectura del resultado en un tiempo supuestamente razonable durante las sesiones observadas.

2) *Percepción y satisfacción del usuario:* La encuesta es

3) *Hallazgos cualitativos:* El análisis del Mapa de Empatía mostró que los usuarios presentan una mezcla de estrés con su salud, falta de conocimiento del verdadero riesgo y necesidad de herramientas claras para actuar. Todo ello permitió argumentar decisiones de diseño del sistema:

- Simplificación de la manera de diagnosticar en 3 pasos guiados.
- Incorporación de una visualización gráfica directa sobre el nivel de riesgo
- Recomendaciones personalizadas de hábitos buenos.

### B. Ajustes realizados al prototipo

Siguiendo el proceso iterativo se tomaron medidas de mejora tras la validación de las primeras versiones del sistema:

- Reorganización de los formularios con el propósito de reducir la carga cognitiva.
- Aumento de la retroalimentación visual tras el envío o navegación entre módulos.
- Contextualización de funcionalidades para futuras integraciones con dispositivos (por ejemplo, smartwatch o correo electrónico).

### C. Limitaciones de los resultados actuales

Al encontrarse esta investigación en una fase de validación preliminar, aún no se han aplicado pruebas de campo sistemáticas en los 100 participantes seleccionados, ni se dispone de métricas cuantitativas estandarizadas. Sin embargo,

la validación estructurada inicial permitió identificar los siguientes hallazgos relevantes:

- La mayoría de los participantes valoraron positivamente contar con una herramienta digital gratuita que permitiera estimar el riesgo cardiovascular.
- El diseño con una interfaz simple, uso de íconos y lenguaje claro fue señalado como una fortaleza importante para su uso.
- Se evidenció una alta disposición a utilizar la plataforma si esta incluía elementos adicionales como recordatorios personalizados y recomendaciones fáciles de aplicar.

A pesar de los avances cualitativos obtenidos, aún no se han recolectado métricas formales de usabilidad tales como:

- Tiempo promedio por tarea.
- Porcentaje de éxito sin asistencia.
- Puntaje SUS u otras escalas validadas de experiencia de usuario.

Dichos indicadores serán recopilados en la siguiente fase, una vez implementado y validado el MVP funcional en entornos clínicos y comunitarios reales.

## VII. CONCLUSIONES

El presente proyecto permitió diseñar y desarrollar una aplicación web predictiva orientada al usuario, cuyo objetivo es estimar el riesgo de enfermedades cardíacas en población adulta. Los resultados evidencian que la combinación de metodologías ágiles (Scrum) junto con enfoques centrados en el usuario (Design Thinking) facilitó la construcción de una solución tecnológica funcional, accesible y alineada con los objetivos planteados.

Los principales avances logrados fueron:

- **Identificación de limitaciones del contexto actual:** Se confirmó la falta de herramientas automatizadas accesibles para la evaluación temprana del riesgo cardiovascular, la dependencia de criterios clínicos subjetivos y la escasez de soluciones digitales disponibles en regiones con baja infraestructura tecnológica. Estos hallazgos justifican la necesidad de una plataforma predictiva fácil de usar, sin requerimientos técnicos avanzados.
- **Construcción de una interfaz accesible y validada:** Gracias al uso de herramientas participativas (entrevistas, pruebas funcionales, retroalimentación de usuarios), se desarrolló una interfaz intuitiva, visualmente clara y adaptable, apta tanto para

pacientes como profesionales de salud, facilitando la interpretación del riesgo mediante elementos gráficos y mensajes personalizados.

- **Aceptación positiva de los usuarios:** Las pruebas funcionales iniciales demostraron una buena recepción; la mayoría de participantes completó el flujo sin asistencia, y varios declararon que la herramienta los motivó a reflexionar sobre sus hábitos de salud, reforzando el componente preventivo del sistema.
- **Desarrollo del MVP en cuatro sprints:** Se implementó un MVP robusto que incluye módulos clave como registro de variables, cálculo automatizado del riesgo, historial de evaluaciones y funciones administrativas orientadas al personal de salud. La arquitectura utilizada (React, Flask, PostgreSQL y TensorFlow) garantiza escalabilidad, rendimiento y posibilidad de despliegue en distintos entornos.
- **Accesibilidad y escalabilidad tecnológica:** El MVP demostró un funcionamiento estable en navegadores y dispositivos móviles. Asimismo, su diseño modular permite futuras integraciones con sistemas institucionales de salud y la actualización continua del modelo predictivo con nuevos datos clínicos.

En síntesis, la propuesta presentada contribuye al fortalecimiento de la prevención en salud cardiovascular en el Perú, al ofrecer una herramienta digital accesible, científicamente fundamentada y con un enfoque educativo. La implementación de sistemas predictivos basados en inteligencia artificial, construidos mediante metodologías ágiles y centradas en el usuario, se presenta como una alternativa viable y escalable para enfrentar los desafíos actuales del sector salud, tanto a nivel nacional como en contextos similares.

## VIII. RECOMENDACIONES

Se recomienda continuar fortaleciendo la precisión del modelo predictivo mediante la ampliación progresiva de la base de datos utilizada, incorporando registros clínicos de usuarios pertenecientes a distintas regiones, realidades socioeconómicas y contextos culturales del país. Este proceso de diversificación permitirá reducir posibles sesgos del modelo y mejorar su capacidad de generalización, especialmente en poblaciones vulnerables o con acceso limitado a servicios de salud especializados.

Asimismo, se sugiere explorar alianzas estratégicas con entidades del sector salud, como el Ministerio de Salud (MINSA), EsSalud u otras instituciones públicas y privadas vinculadas a la atención cardiometaabólica. Dichas



colaboraciones podrían facilitar la integración de la aplicación dentro de campañas de tamizaje, programas preventivos o evaluaciones periódicas en establecimientos de salud. Además, permitirían acceder a bases de datos oficiales para validar el modelo a mayor escala y fortalecer la confiabilidad de los resultados.

En complemento, resulta pertinente desarrollar estrategias de difusión y alfabetización digital orientadas a promover el uso responsable y sostenido de la plataforma. Estas acciones deberían estar dirigidas principalmente a personas adultas con bajos niveles de familiaridad tecnológica. Para ello, se sugiere producir materiales didácticos como tutoriales en video, guías visuales simplificadas o sesiones informativas presenciales en centros de salud y espacios comunitarios.

De igual manera, se recomienda mantener un sistema de retroalimentación continua que permita recoger sugerencias de los usuarios respecto a nuevas funcionalidades, tales como recordatorios personalizados, historial visual de evaluaciones, recomendaciones dinámicas según nivel de riesgo u opciones de seguimiento progresivo. Estas mejoras incrementarían la utilidad percibida y fomentarían cambios sostenibles en los hábitos de salud.

Finalmente, se considera fundamental mantener el uso de metodologías ágiles como Scrum para las futuras etapas de mejora y actualización del sistema. Esto permitirá implementar cambios de manera rápida, iterativa y basada en evidencia, respondiendo de forma eficiente a las necesidades reales de los usuarios y del sector salud.

## REFERENCIAS

- Aghili, M., Tabarestani, S., Adjouadi, M., & Adeli, E. (2018). Predictive modeling of longitudinal data for Alzheimer's disease diagnosis using RNNs. In *PRedictive Intelligence in MEDicine (PRIME 2018)* (pp. 112–119). [https://doi.org/10.1007/978-3-030-00320-3\\_14](https://doi.org/10.1007/978-3-030-00320-3_14)
- Bootun, D., Auzine, M. M., Ayesha, N., Idris, S., Saba, T., & Heenaye-Mamode Khan, M. (2025). ADAMAEX—Alzheimer's disease classification via attention-enhanced autoencoders and XAI. *Egyptian Informatics Journal*, 28, 100688. <https://doi.org/10.1016/j.eij.2025.100688>
- Dakshinamoorthy, C., Prabha S., Mathivanan, S. K., Singh, M., & Mallik, S. (2025). A comprehensive hybrid model: Combining bioinspired optimization and deep learning for Alzheimer's disease identification. *Computers in Biology and Medicine*, 178, 110654. <https://doi.org/10.1016/j.compbiomed.2025.110654>
- Ibáñez, C., Simó, C., Martín-Álvarez, P. J., Kivipelto, M., Winblad, B., Cedazo-Minguez, A., & Cifuentes, A. (2012). Toward a predictive model of Alzheimer's disease progression using capillary electrophoresis–mass spectrometry metabolomics. *Analytical Chemistry*, 84(20), 8532–8540. <https://doi.org/10.1021/ac301243k>
- Islam, M. T., & Alyasiri, S. A. (2019). Transfer learning with intelligent training data selection for prediction of Alzheimer's disease. *IEEE Access*, 7, 145017–145032. <https://doi.org/10.1109/ACCESS.2019.2920448>
- Jumaili, M. L. F., & Sonuç, E. (2025). An attention-based CNN framework for Alzheimer's disease staging with multi-technique XAI visualization. *CMC-Computers, Materials & Continua*, 80(2), 2101–2125. <https://doi.org/10.32604/cmc.2025.062719>
- Liu, S., Liu, S., Cai, W., & Che, H. (2020). Automated MRI-based deep learning model for detection of Alzheimer's disease process. *International Journal of Neural Systems*, 30(6). <https://doi.org/10.1142/S012906572050032X>
- Morra, J. H., Tu, Z., Apostolova, L. G., Green, A. E., Toga, A. W., & Thompson, P. M. (2019). A deep learning model for early prediction of Alzheimer's disease dementia based on hippocampal magnetic resonance imaging data. *Alzheimer's & Dementia*, 15(8), 1059–1070. <https://doi.org/10.1016/j.jalz.2019.02.007>
- Nan, F., Li, S., Wang, J., Tang, Y., Qi, J., & Zhou, M. (2022). A multi-classification assessment framework for reproducible evaluation of multimodal learning in Alzheimer's disease. *IEEE Journal of Biomedical and Health Informatics*, 26(10), 5123–5134. <https://doi.org/10.1109/TCBB.2022.3204619>
- Nour, M., Senturk, U., & Polat, K. (2024). A novel hybrid model in the diagnosis and classification of Alzheimer's disease using EEG signals: Deep ensemble learning (DEL) approach. *Biomedical Signal Processing and Control*, 89, 105751. <https://doi.org/10.1016/j.bspc.2023.105751>
- Sangeetha, S., & Nair, S. A. (2023). A systematic review on machine learning and deep learning techniques in the effective diagnosis of Alzheimer's disease. *Brain Informatics*, 10(1), 25. <https://doi.org/10.1186/s40708-023-00195-7>
- Shaffi, N., Subramanian, K., Vimbi, V., Hajamohideen, F., Abdesselam, A., & Mahmud, M. (2024). Performance evaluation of deep, shallow and ensemble machine learning methods for the automated classification of Alzheimer's disease. *International Journal of Neural Systems*, 34(10), 2450029. <https://doi.org/10.1142/S0129065724500291>
- Singhania, U., Tripathy, B., Hasan, M. K., Anumbe, N. C., Alboaneen, D., Ahmed, F. R. A., Ahmed, T. E., & Nour,



M. M. M. (2021). *A predictive and preventive model for onset of Alzheimer's disease*. *Frontiers in Public Health*, 9, 751536. <https://doi.org/10.3389/fpubh.2021.751536>

Vinukonda, E. R., & Jagadesh, B. N. (2024). *An integrated deep learning model for early and multi-class diagnosis of Alzheimer's disease from MRI scans*. *Scientific Reports*, 14, 12345. <https://doi.org/10.1038/s41598-025-01845-y>

Wang, T., Qiu, R. G., & Yu, M. (2018). *Predictive modeling of the progression of Alzheimer's disease with recurrent neural networks*. *Scientific Reports*. <https://doi.org/10.1038/s41598-018-27337-w>

Wang, X., Zhou, S., Ye, N., Li, Y., Zhou, P., Chen, G., & Hu, H. (2024). *Predictive models of Alzheimer's disease dementia risk in older adults with mild cognitive impairment: A systematic review and critical appraisal*. *BMC Geriatrics*, 24, 531. <https://doi.org/10.1186/s12877-024-05044-8>

You, J., Zhang, Y.-R., Wang, H.-F., Yang, M., Feng, J.-F., Yu, J.-T., & Cheng, W. (2022). *Development of a novel dementia risk prediction model in the general population: A large, longitudinal, population-based machine-learning study*. *eClinicalMedicine*, 53, 101665. <https://doi.org/10.1016/j.eclinm.2022.101665>

You want, Autor(es). (2022). *A predictive model using the mesoscopic architecture of the living brain to detect Alzheimer's disease*. *Communications Medicine*. <https://doi.org/10.1038/s43856-022-00133-4>

You, J., Zhang, Y.-R., Wang, H.-F., Yang, M., Feng, J.-F., Yu, J.-T., & Cheng, W. (2022). *Development of a novel dementia risk prediction model in the general population: A large, longitudinal, population-based machine-learning study*. *eClinicalMedicine*, 53, 101665. <https://doi.org/10.1016/j.eclinm.2022.101665>